

SAE 203 – Régression sur données réelles

Université Sorbonne Paris Nord
IUT de Villetaneuse
Département Sciences des Données
Promotion 2025-2026

Binôme : **Abel ROOBAN** et **Jérémy DELETANG**

Date : 19/06/2026

Nous avons choisi de réaliser tout le code nécessaire à la réalisation de cette SAÉ en **R**.

Chargement des données :


```
In [ ]: data <- read.csv("C:/Users/jerem/Documents/12502204/SD/S2/SAEs/S2.03/matériels/data.csv", header = TRUE)
```

Partie 1 :

Question 1 :

```
In [ ]: propMB<-table(data$diagnosis)
pie(propMB,labels = propMB,main = "Répartition des tumeurs", col = c("lightgreen", "blue"))
legend("topright",legend = c("Bénigne (B)", "Maligne (M)"),fill = c("lightgreen", "blue"))
```


Répartition des tumeurs



Question 2 :

```
In [ ]: radius <- data$radius_mean
hist(radius, main = "Histogramme du rayon moyen", xlab = "Rayon moyen", ylab = "Effectif", col = "lightgreen")
```

Histogramme du rayon moyen



Analyses :

On voit sur le graphique que la plupart des tumeurs sont petites, avec un rayon entre 10 et 16 unités.


Comme on sait qu'il y a 63 % de cas bénins dans le fichier, on peut deviner que la gauche du graphique

correspond aux tumeurs sans danger, tandis que les tumeurs plus grosses à droite ont de grandes chances d'être malignes.

Question 3 :

```
In [ ]: radiusB <- data$radius_mean[data$diagnosis == "B"]
radiusM <- data$radius_mean[data$diagnosis == "M"]
hist(radiusB, main = "Histogramme du rayon moyen selon le diagnostic", xlab = "Rayon moyen", ylab = "Effectif",
      col = "lightgreen")
hist(radiusM, col = "pink", add = TRUE)
legend("topright", legend = c("Bénigne", "Maligne"), fill = c("lightgreen", "pink"))
```

Histogramme du rayon moyen selon le diagnostic



Question 4 :

En cherchant, nous avons trouvé que pour afficher nos dix histogrammes sur deux colonnes et cinq lignes, il faut configurer l'espace graphique avec cette commande : `par(mfrow = c(5, 2))` et `par(mfrow = c(1,1))` pour revenir à l'affichage normal.

```
In [ ]: par(mfrow = c(5,2))

hist(radiusB, main="radius_mean", col="lightgreen")
hist(radiusM, col="pink", add=TRUE)

textureB <- data$texture_mean[data$diagnosis=="B"]
textureM <- data$texture_mean[data$diagnosis=="M"]

hist(textureB, main="texture_mean", col="lightgreen")
hist(textureM, col="pink", add=TRUE)

perimeterB <- data$perimeter_mean[data$diagnosis=="B"]
perimeterM <- data$perimeter_mean[data$diagnosis=="M"]

hist(perimeterB, main="perimeter_mean", col="lightgreen")
hist(perimeterM, col="pink", add=TRUE)

areaB <- data$area_mean[data$diagnosis=="B"]
areaM <- data$area_mean[data$diagnosis=="M"]

hist(areaB, main="area_mean", col="lightgreen")
hist(areaM, col="pink", add=TRUE)

smoothnessB <- data$smoothness_mean[data$diagnosis=="B"]
smoothnessM <- data$smoothness_mean[data$diagnosis=="M"]

hist(smoothnessB, main="smoothness_mean", col="lightgreen")
hist(smoothnessM, col="pink", add=TRUE)

compactnessB <- data$compactness_mean[data$diagnosis=="B"]
compactnessM <- data$compactness_mean[data$diagnosis=="M"]
```

```

hist(compactnessB, main="compactness_mean", col="lightgreen")
hist(compactnessM, col="pink", add=TRUE)

concavityB <- data$concavity_mean[data$diagnosis=="B"]
concavityM <- data$concavity_mean[data$diagnosis=="M"]

hist(concavityB, main="concavity_mean", col="lightgreen")
hist(concavityM, col="pink", add=TRUE)

concaveB <- data$concave.points_mean[data$diagnosis=="B"]
concaveM <- data$concave.points_mean[data$diagnosis=="M"]

hist(concaveB, main="concave.points_mean", col="lightgreen")
hist(concaveM, col="pink", add=TRUE)


symmetryB <- data$symmetry_mean[data$diagnosis=="B"]
symmetryM <- data$symmetry_mean[data$diagnosis=="M"]

hist(symmetryB, main="symmetry_mean", col="lightgreen")
hist(symmetryM, col="pink", add=TRUE)

fractalB <- data$fractal_dimension_mean[data$diagnosis=="B"]
fractalM <- data$fractal_dimension_mean[data$diagnosis=="M"]

hist(fractalB, main="fractal_dimension_mean", col="lightgreen")
hist(fractalM, col="pink", add=TRUE)

```



Question 5 :

Une variable est dite discriminante lorsqu'elle permet de distinguer efficacement deux groupes d'individus.

Dans notre étude, une variable est considérée comme discriminante si ses valeurs sont différentes entre les tumeurs bénignes et les tumeurs malignes.

À partir des histogrammes précédents, on observe que les variables radius_mean, perimeter_mean, area_mean, compactness_mean, concavity_mean et concave.points_mean semblent être les plus discriminantes.


En effet, les distributions des tumeurs bénignes et malignes sont relativement bien séparées, ce qui facilite leur distinction.

À l'inverse, les variables symmetry_mean et fractal_dimension_mean présentent un fort chevauchement entre les deux diagnostics et semblent donc moins pertinentes pour différencier les tumeurs.

Question 6 :

```
In [ ]: par(mfrow = c(1,1)) # Remettre l'affichage normal

plot(radiusB, textureB, col = "green", pch = 19, xlab = "Rayon moyen", ylab = "Texture moyenne",
      main = "Texture en fonction du rayon")
points(radiusM, textureM, col = "pink", pch = 19)
legend("topleft", legend = c("Bénigne", "Maligne"), col = c("green", "pink"), pch = 19)
```



Le nuage de points met en évidence une légère corrélation positive entre le rayon moyen et la texture moyenne. En effet, lorsque le rayon moyen augmente, la texture moyenne a tendance à augmenter également. Cependant, les points restent relativement dispersés, ce qui indique que cette corrélation n'est pas très forte. Concernant la classification des tumeurs, on observe que les tumeurs bénignes sont principalement concentrées pour les faibles valeurs du rayon moyen, tandis que les tumeurs malignes sont davantage présentes pour les valeurs élevées. Bien qu'il existe une zone de chevauchement entre les deux groupes, le rayon moyen semble permettre une bonne distinction entre les tumeurs bénignes et malignes. La texture moyenne apporte également des informations mais paraît moins discriminante que le rayon moyen.

Question 7 :

L'étude du nuage de points permet de confirmer les conclusions obtenues à la question précédente. En effet, les tumeurs bénignes et malignes occupent majoritairement des zones différentes du graphique. Les tumeurs bénignes sont principalement associées à de faibles valeurs du rayon moyen tandis que les tumeurs malignes présentent des valeurs plus élevées. Cette représentation confirme donc le caractère discriminant du rayon moyen. La texture moyenne semble également apporter des informations utiles pour la classification, mais son pouvoir discriminant apparaît plus faible. Les observations réalisées sur le nuage de points sont donc cohérentes avec celles obtenues à partir des histogrammes.

Question 8 :

Parmi les variables étudiées, concave.points_mean apparaît comme particulièrement discriminante.

La moyenne des tumeurs bénignes est de 0,0257 contre 0,0880 pour les tumeurs malignes.

Nous proposons donc un seuil de 0,0569.

Ainsi, une tumeur dont la valeur de concave.points_mean est inférieure à 0,0569 sera classée comme bénigne, tandis qu'une tumeur dont la valeur est supérieure à ce seuil sera classée comme maligne.

Partie 2 :

Question 1 :

Le nombre de combinaisons possibles revient à faire 2 parmi 5, ceci nous donne alors 10 combinaisons possibles.

Ensuite, nous avons déterminé les liens de corrélation entre nos 5 variables.

Les résultats de la question 1 montrent que les variables liées à la taille de la tumeur comme radius_mean, perimeter_mean et area_mean sont très fortement corrélées entre elles avec des coefficients proches de 1.

Cela traduit une relation quasi linéaire parfaite entre ces variables.

À l'inverse, les variables comme concavity_mean présentent des corrélations intermédiaires avec les variables de taille indiquant une relation positive mais moins marquée.

Enfin, compactness_mean est moins fortement corrélée, ce qui suggère une relation plus faible et plus dispersée avec les variables de taille.

Les résultats sont les suivants :

	radius	perimeter	area	compactness	concavity
radius	1.0000	0.9979	0.9874	0.5061	0.6768
perimeter	0.9979	1.0000	0.9865	0.5569	0.7161
area	0.9874	0.9865	1.0000	0.4985	0.6860
compactness	0.5061	0.5569	0.4985	1.0000	0.8831
concavity	0.6768	0.7161	0.6860	0.8831	1.0000

```
In [ ]: # Le code associé :
radius <- data$radius_mean
radius <- data$radius_mean
perimeter <- data$perimeter_mean
area <- data$area_mean
compactness <- data$compactness_mean
concavity <- data$concavity_mean

df2 <- data.frame(radius,perimeter,area,compactness,concavity)
round(cor(df2), 4)
```

Question 2 :


On a choisi de réaliser un ajustement linéaire entre le rayon moyen et le périmètre moyen car ils possèdent un coefficient de corrélation presque parfait ($r = 0.9979$).

Le graphique montre clairement que la droite de régression s'ajuste idéalement au nuage de points car plus le rayon d'une cellule augmente plus son périmètre grandit de manière proportionnelle.

Le code utilisé :

```
In [ ]: plot(df2$radius[data$diagnosis == "B"], df2$perimeter[data$diagnosis == "B"], col = "green", pch = 19,
  xlab = "Rayon moyen", ylab = "Périmètre moyen", main = "Périmètre en fonction du rayon",
  xlim = range(df2$radius), ylim = range(df2$perimeter))
points(df2$radius[data$diagnosis == "M"], df2$perimeter[data$diagnosis == "M"], col = "pink", pch = 19)
abline(mod_perim, col = "black", lwd = 2)
legend("topleft", legend = c("Bénigne", "Maligne"), col = c("green", "pink"), pch = 19)
```

Périmètre en fonction du rayon



Conclusion :

La couleur des points montre que les tumeurs bénignes (vert) restent petites avec de faibles rayons et périmètres alors que les tumeurs malignes (rose) tendent vers des valeurs beaucoup plus grandes.

En conclusion, nos graphiques montrent une différence : les tumeurs bénignes restent petites avec des rayons et des périmètres faibles. À l'inverse, les tumeurs malignes atteignent des tailles beaucoup plus grandes.

La séparation bien visible des couleurs sur le graphique prouve que la taille et le périmètre sont d'excellents indicateurs. Ils peuvent permettre de distinguer facilement les deux types de tumeurs et à poser le bon diagnostic.